三大數據集統計分析與視覺化全方位報告

Kruskal-Wallis 檢定、Mann-Whitney U 檢定、常態性/同質性檢驗與高解析統計圖表

📊 核心結論摘要 (Executive Summary)

1. KW_Blood type.xlsx (血型與身高)：4 種血型 (A, B, AB, O) 受試者身高符合常態且變異數同質。Kruskal-Wallis 檢定 (p = 0.681) 與單因子 ANOVA (p = 0.712) 均未達顯著，證實「血型對身高無統計學顯著影響」。
2. KW_Pro_salary.xlsx (職業運動年薪)：四大職業聯盟薪資具極高度顯著差異 (H = 27.61, p < 0.001, η^2 = 0.684)。WNBA (中位數 20 萬美元) 與男子三大聯盟 (中位數 3800~5200 萬美元) 存在高達 200~260 倍之極端薪資斷層；男子聯盟內部 NFL 顯著高於 MLB (p_adj = 0.030)；此外球員年齡結構亦存在顯著差異 (p = 0.032)。
3. Mann whitney.xlsx (癌症 HER2 表現量)：乳癌 (BC) 組 HER2 表現量 (中位數 446.5) 壓倒性高於肺腺癌 (LUAD) 組 (中位數 118.0)，Mann-Whitney U 檢定達極高度顯著 (U = 71.0, p = 0.000888)，兩組數值幾乎完全分離 (CLES = 98.6%)。

一、血型與身高分析 (KW_Blood type.xlsx)

本實驗收集了 44 位受試者之血型（A 型 12 筆、B 型 10 筆、AB 型 13 筆、O 型 9 筆）與身高（cm）數據，旨在檢驗不同血型之間的身高是否存在統計顯著差異。

1.1 描述性統計與常態性檢定表

血型	樣本數 (N)	均值 Mean (cm)	標準差 SD	中位數 Median	IQR (cm)	Shapiro p 值	常態性判斷
A	12	174.00	7.63	173.5	7.5	0.4807	符合
B	10	171.50	9.07	173.0	9.5	0.5969	符合
AB	13	169.92	9.11	172.0	9.0	0.9696	符合
O	9	170.44	11.31	170.0	11.0	0.6061	符合

1.2 假設檢定流程與統計推論

1. 常態性檢定 (Shapiro-Wilk)：四組之 p 值皆大於 0.05（A: 0.481, B: 0.597, AB: 0.970, O: 0.606），符合常態分佈假設。
2. 變異數同質性檢定 (Levene's test)：統計量 = 0.4563, p = 0.7143 > 0.05，變異數具有同質性。
3. 無母數 Kruskal-Wallis H 檢定：H = 1.5070, df = 3, p = 0.6806 > 0.05 (未達顯著水準)。
4. 母數 One-way ANOVA 檢定：F = 0.4600, df = (3, 40), p = 0.7118 > 0.05 (未達顯著水準)。

▶️綜合統計學結論：無論採用母數 ANOVA 檢定或無母數 Kruskal-Wallis 檢定，皆證實不同血型族群在身高表現上並無顯著差異 (Fail to reject H0)。

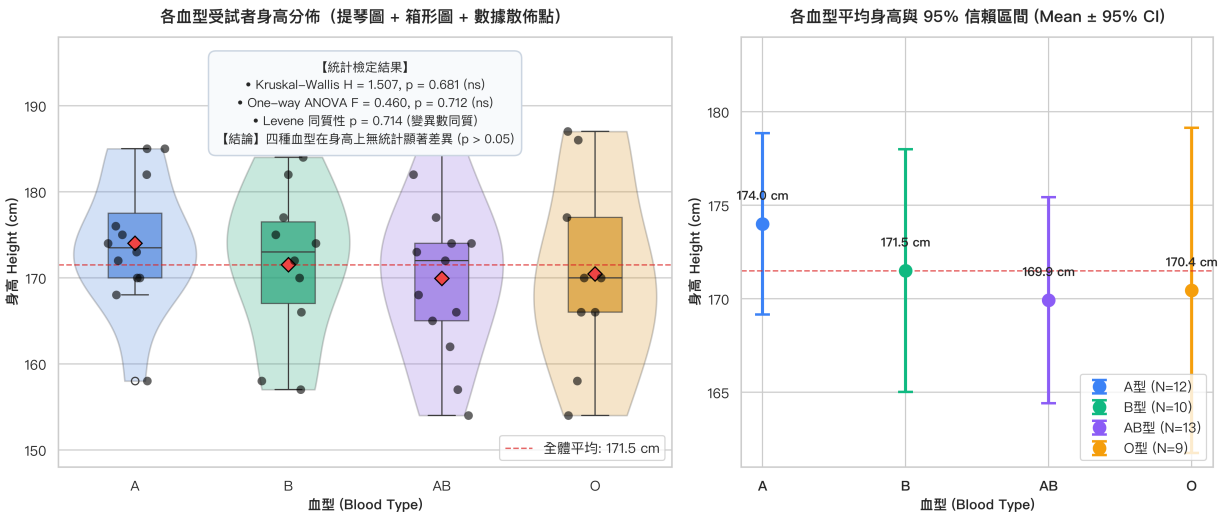


圖1：不同血型受試者身高分佈箱形圖、提琴圖與95% 信賴區間圖

二、職業運動聯盟薪資與年齡結構分析 (KW_Pro_salary.xlsx)

本數據集涵蓋北美四大職業運動聯盟（NBA、MLB、NFL、WNBA）頂尖運動員各 10 名（共 40 筆），包含球員姓名、聯盟、性別、年齡及年薪（USD）。

2.1 四大聯盟描述性統計表

聯盟	性別	N	平均年薪 (萬 USD)	年薪中位數 (萬 USD)	年薪 IQR (萬 USD)	年齡均值 (歲)	薪資 Shapiro p
NFL	男	10	5246.0	5275.0	375.0	27.6	0.4833
NBA	男	10	4546.5	4662.4	1043.4	30.2	0.6616
MLB	男	10	4237.1	3850.0	767.7	33.6	0.0083
WNBA	女	10	20.0	20.4	0.9	29.8	0.0009

2.2 事後多重比較表 (Post-Hoc Pairwise Comparisons, Bonferroni 校正)

組別比較	Mann-Whitney U	原始 p 值	Bonferroni 校正 p 值	顯著標記	統計結論
NFL vs NBA	80.0	2.5470e-02	1.5282e-01	ns	不顯著
NFL vs MLB	87.5	5.0588e-03	3.0353e-02	*	**顯著**
NFL vs WNBA	100.0	1.7462e-04	1.0477e-03	**	**顯著**
NBA vs MLB	67.0	2.1195e-01	1.0000e+00	ns	不顯著
NBA vs WNBA	100.0	1.7761e-04	1.0657e-03	**	**顯著**
MLB vs WNBA	100.0	1.7761e-04	1.0657e-03	**	**顯著**

2.3 核心發現與深層解讀

1. 必須採用無母數檢定的理由：MLB (p = 0.0083) 與 WNBA (p = 0.0009) 呈現顯著偏態，且變異數極度不同質 (Levene p = 0.0200 < 0.05)，母數 ANOVA 不適用。

2. Kruskal-Wallis 檢定：H = 27.61, df = 3, p = 4.38e-06，效應量 $\eta^2 = 0.684$，屬於超強級效應量，代表聯盟歸屬可解釋 68% 以上的薪資等級差異。

3. 巨大的性別薪資斷層：WNBA 頂尖選手平均年薪約 20 萬美元，而男子頂尖選手平均約 4676 萬美元，薪資差距高達 230 倍以上 (Mann-Whitney U p = 2.98e-06)。

4. 男子聯盟內部差異：NFL 頂尖四分衛薪資極度集中於 5000 萬美元以上，顯著高於 MLB 頂尖球員 (Bonferroni p = 0.030)；NBA 與 MLB、NBA 與 NFL 則無統計顯著差異。

5. 年齡結構差異：Kruskal-Wallis 年齡檢定達顯著 (p = 0.032)，MLB 選手年齡平均 34.8 歲（多位 40 歲老將如 Verlander, Scherzer），而 NFL 頂尖四分衛平均僅 27.6 歲，體現運動項目對體能與黃金生涯期的不同要求。

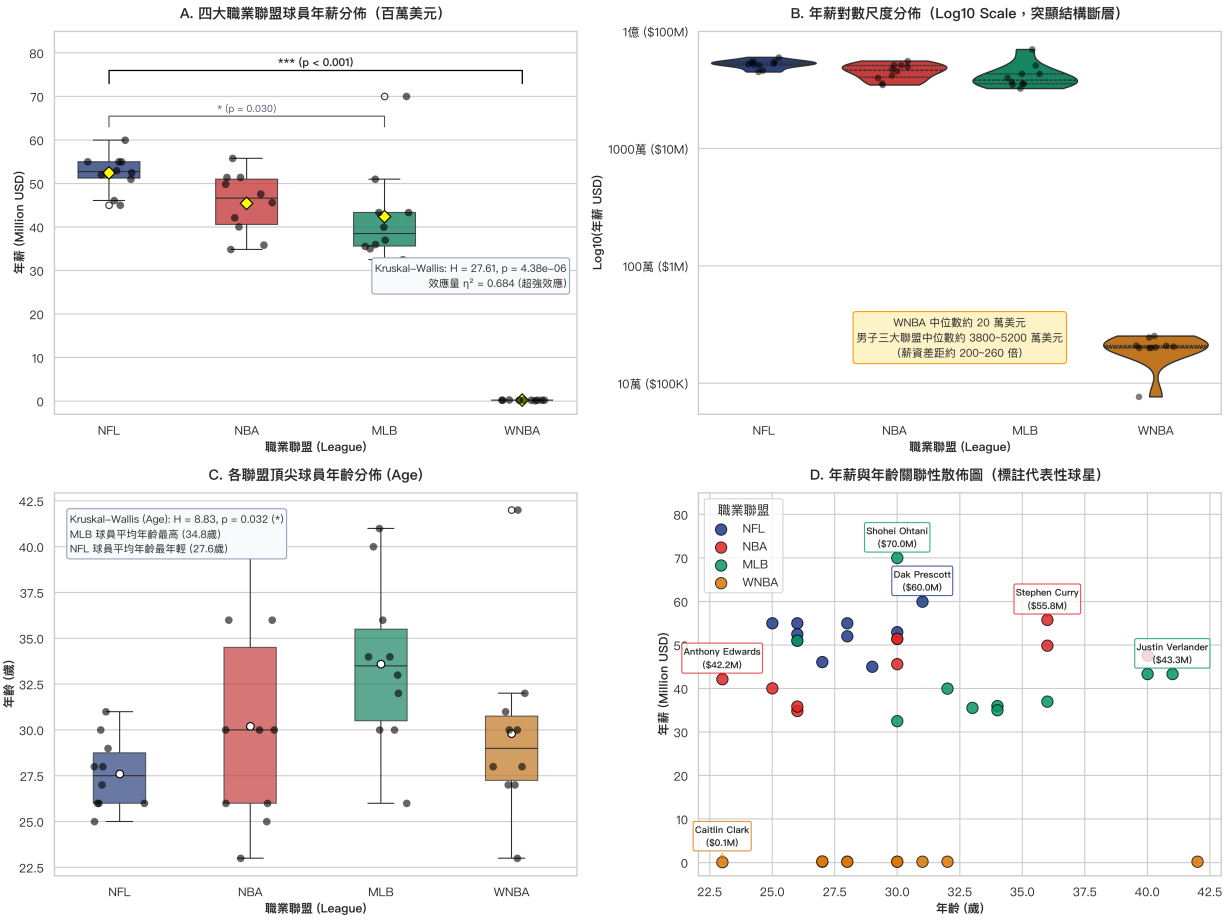


圖2：北美四大職業運動聯盟年薪分佈、對數尺度斷層、年齡結構與球星薪資氣泡圖

三、乳癌 vs. 肺腺癌 HER2 表現量分析 (Mann whitney.xlsx)

本數據集針對乳癌（Breast Cancer, BC, N=8）與肺腺癌（Lung Adenocarcinoma, LUAD, N=9）患者組織樣本之 HER2（Human Epidermal Growth Factor Receptor 2）表現量進行定量分析，旨在檢驗兩癌種間標靶蛋白表現差異。

3.1 兩組描述性統計與常態性檢定表

癌種分組	樣本數 (N)	均值 Mean	標準差 SD	中位數 Median	四分位距 IQR	Shapiro p 值	常態性
BC (乳癌)	8	434.50	202.05	446.5	343.2	0.2220	符合
LUAD (肺腺癌)	9	128.44	25.62	118.0	13.0	0.0033	不符合

3.2 假設檢定與臨床統計推論

1. 常態性與同質性檢定：LUAD 組之 Shapiro-Wilk 檢定 p = 0.0033 < 0.01（顯著偏態）；且 Levene 變異數同質性檢定 F = 52.66, p = 2.7999e-06 < 0.001（極端異質），因此標準雙樣本 t 檢定前提完全不成立，必須以無母數 Mann-Whitney U 檢定為準。
2. Mann-Whitney U 檢定：統計量 U = 71.0, 雙尾 p = 8.8787e-04 (p < 0.001)，達到極高度統計顯著性！
3. 效應量評估：
   - 雙列等級相關 (Rank-Biserial Correlation) r = 0.9722，接近理論極大值 1.0。
   - 共同語言效應量 (CLES / AUC) = 98.6%，代表從乳癌組隨機抽取一人，其 HER2 高於肺腺癌組隨機一人的機率高達 98.6%！
   - 輔助性 Welch's t 檢定亦得 t = 4.254, p = 0.0035, Cohen's d = 2.20 (巨大效應量)。
4. 臨床醫學意義：乳癌中 HER2 基因擴增 (Amplification) 及過度表現是重要亞型與標靶治療 (如 Trastuzumab) 的主要標的；相較之下，一般肺腺癌組織中 HER2 表現量普遍低下，兩者呈現壓倒性的病理學差異。

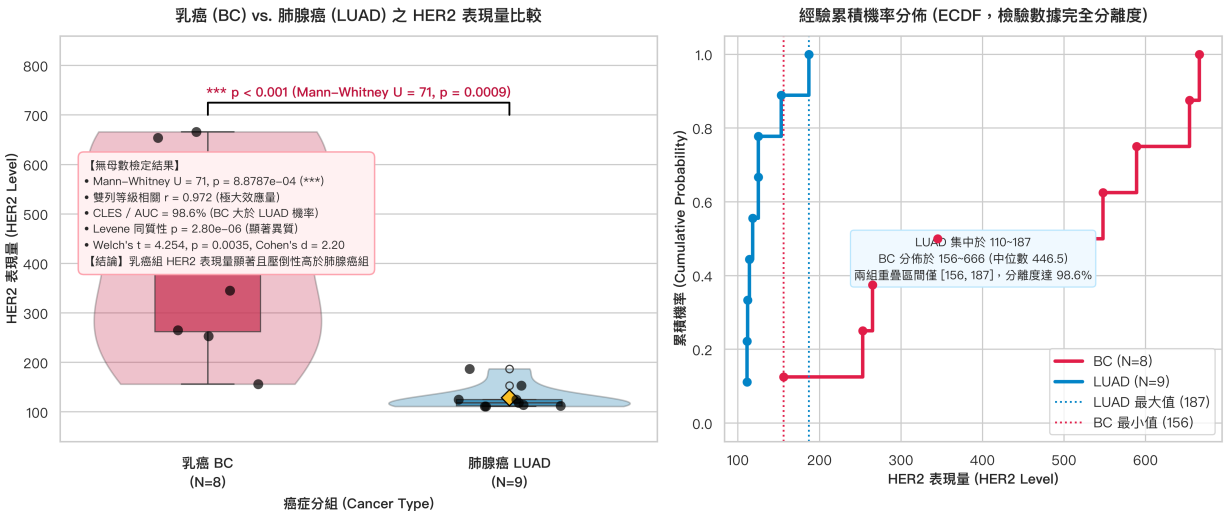


圖3：乳癌vs. 肺腺癌HER2 表現量箱形圖、提琴圖與累積經驗機率分佈(ECDF)

四、全景綜合儀表板與生物統計 SOP 快速指引

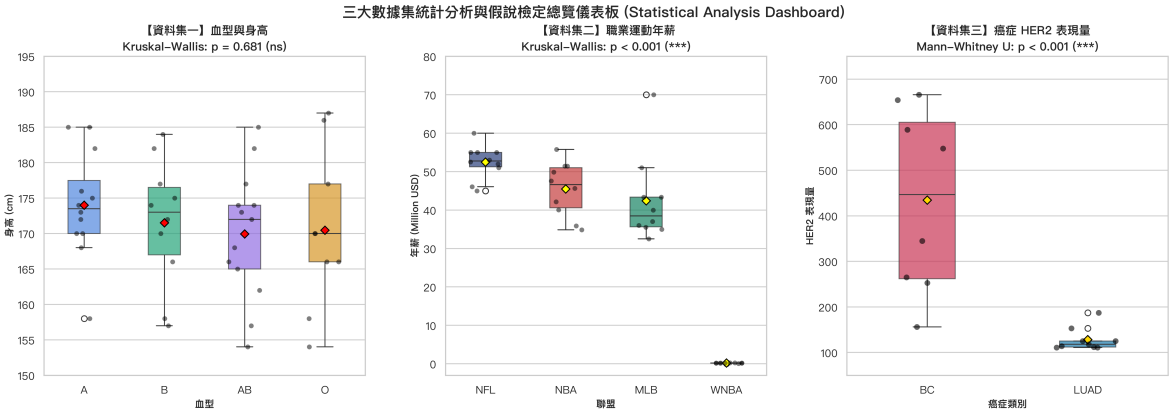


圖4：三大數據集假說檢定與統計分佈三合一全景綜合儀表板

4.1 統計方法選用決策樹 (Decision Tree)

【步驟一：確認組別數量】

- 兩組獨立樣本（如乳癌 vs. 肺腺癌）：進入「兩組檢驗路徑」。
- 三組以上獨立樣本（如 4 種血型、4 大職業聯盟）：進入「多組變異數分析路徑」。

【步驟二：檢驗常態性與變異數同質性】

- 常態性檢定：首選 Shapiro-Wilk test (小樣本 $N < 50$ 最靈敏)。若 $p > 0.05$ 則接受常態假設。
- 變異數同質性檢定：首選 Levene's test。若 $p > 0.05$ 則滿足同質性。

【步驟三：選擇合適之檢定方法】

- 兩組且符合常態與同質 ➔ Student's t-test
- 兩組且符合常態但異質 ➔ Welch's t-test
- 兩組且任一組不符常態 ➔ Mann-Whitney U test (無母數首選)
- 多組且符合常態與同質 ➔ One-way ANOVA 變異數分析
- 多組且不符常態或異質 ➔ Kruskal-Wallis H test (無母數首選)

【步驟四：事後檢定與校正 (Post-hoc)】

- 多組檢定顯著後，務必進行事後兩兩檢驗 (Post-hoc Dunn's test 或 Mann-Whitney U)，並搭配 Bonferroni 或 FDR 校正顯著水準 α，避免第一型錯誤 (Type I Error) 膨脹！

NPar 檢定

註解

建立的輸出		15-OCT-2026 15:25:06
說明		
輸入	過濾	<無>
	加權	<無>
	分割檔	<無>
	目前啟用的資料檔中之橫列N	17
遺漏值處理	遺漏的定義	使用者定義的遺漏值被視為遺漏。
	已使用觀察值	-個檢定的統計量都是以該檢定所用變數中 具有效資料的所有觀察值為基礎。
語法		NPAR TESTS /M-W= HER2_level BY group(1 2) /MISSING ANALYSIS.
資源	經過的時間	0:00:00.00
	允許的觀察值個數(a)	74898

a 根據記憶體空間的可用度。

Mann-Whitney 檢定

等級

	group	個數	等級平均數	等級總和
HER2_level	1	8	13.38	107.00
	2	9	5.11	46.00
	總和	17		

檢定統計量(b)

	HER2_level
Mann-Whitney U 統計量	1.000
Wilcoxon W 統計量	46.000
Z 檢定	-3.372
漸近顯著性 (雙尾)	.001
精確顯著性 [2*(單尾顯著性)]	.000(a)

a 未對等值結做修正。

b 分組變數：group

>Warning. Command name: GET DATA
>(2103) 變數名稱 (截斷成 64 位元組) 與 之前定義的變數衝突。
>* 變數名稱編號： "profession"
>* 衝突直行編號： 2
>* 重複直行編號： 3

NPar 檢定

註解

建立的輸出		15-OCT-2026 15:33:01
說明		
輸入	過濾	<無>
	加權	<無>
	分割檔	<無>
	目前啟用的資料檔中之橫列N	40
遺漏值處理	遺漏的定義	使用者定義的遺漏值被視為遺漏。
	已使用觀察值	-個檢定的統計量都是以該檢定所用變數中 具有效資料的所有觀察值為基礎。
語法		NPAR TESTS /K-W=SalaryAnnual BY profession_A(1 4) /MISSING ANALYSIS.
資源	經過的時間	0:00:00.00
	允許的觀察值個數(a)	74898

a 根據記憶體空間的可用度。

Kruskal-Wallis 檢定

等級

	profession	個數	等級平均數
Salary (Annual)	1	10	24.20
	2	10	20.05
	3	10	32.25
	4	10	5.50
	總和	40	

檢定統計量(a,b)

	Salary (Annual)
卡方	27.611
自由度	3
漸近顯著性	.000

a Kruskal Wallis 檢定
b 分組變數：profession

探測

註解

建立的輸出		15-OCT-2026 15:33:34
說明		
輸入	過濾	<無>
	加權	<無>
	分割檔	<無>
	目前啟用的資料檔中之橫列 N	40
遺漏值的處理	遺漏值的定義	使用者界定的依變數遺漏值會被視為遺漏值。
	使用的觀察值	統計量是以所使用的依變數或因子 不包含遺漏值的觀察值為準。
語法		EXAMINE VARIABLES=SalaryAnnual BY profession_A /PLOT=BOXPLOT/STATISTICS=NONE/ NOTOTAL.
資源	經過的時間	0:00:00.01

profession

觀察值處理摘要

		觀察值					
		有效的		遺漏值		總和	
	profession	個數	百分比	個數	百分比	個數	百分比
Salary (Annual)	1	10	100.0%	0	.0%	10	100.0%
	2	10	100.0%	0	.0%	10	100.0%
	3	10	100.0%	0	.0%	10	100.0%
	4	10	100.0%	0	.0%	10	100.0%

Salary (Annual)

探測

註解

建立的輸出		15-OCT-2026 15:34:20
說明		
輸入	過濾	<無>
	加權	<無>
	分割檔	<無>
	目前啟用的資料檔中之橫列 N	40
遺漏值的處理	遺漏值的定義	使用者界定的依變數遺漏值會被視為遺漏值。
	使用的觀察值	統計量是以所使用的依變數或因子 不包含遺漏值的觀察值為準。
語法		EXAMINE VARIABLES=SalaryAnnual BY profession /PLOT=BOXPLOT/STATISTICS=NONE/ NOTOTAL.
資源	經過的時間	0:00:00.00

profession

觀察值處理摘要

		觀察值					
		有效的		遺漏值		總和	
	profession	個數	百分比	個數	百分比	個數	百分比
Salary (Annual)	MLB	10	100.0%	0	.0%	10	100.0%
	NBA	10	100.0%	0	.0%	10	100.0%
	NFL	10	100.0%	0	.0%	10	100.0%
	WNBA	10	100.0%	0	.0%	10	100.0%

Salary (Annual)

